

Уникальные вопросы с открытым ответом по NLP с ответами

Уникальные вопросы с открытым ответом по NLP с ответами

Из предыдущего PDF извлечено **160** вопросов с открытым ответом. После удаления повторяющихся и близких по смыслу вопросов осталось **55** уникальных вопросов. Ниже у каждого вопроса добавлен ответ из исходного PDF.

1. Запишите математическую формулу закона Ципфа, связывающую частоту слова с его рангом, и поясните, что такое ранг.

Встречается: Вариант 10, вопрос 1; Вариант 29, вопрос 1; Вариант 27, вопрос 1.

Ответ:

Закон Ципфа:

$$f(w) \approx \frac{C}{r(w)^\alpha}, \quad \alpha \approx 1$$

где $f(w)$ — частота слова, $r(w)$ — ранг слова в списке по убыванию частоты, C — константа. Ранг 1 имеет самое частое слово, ранг 2 — второе по частоте и т.д.

2. Назовите два применения/следствия закона Ципфа, важных для построения NLP-моделей.

Встречается: Вариант 10, вопрос 2; Вариант 17, вопрос 1; Вариант 29, вопрос 2; Вариант 27, вопрос 2.

Ответ:

Во-первых, он помогает находить стоп-слова: самые частые слова часто малоинформативны. Во-вторых, он помогает анализировать словарь корпуса: редкие слова можно отфильтровывать или обрабатывать отдельно.

3. Сформулируйте допущение Маркова n-го порядка в языковой модели.

Встречается: Вариант 10, вопрос 3; Вариант 17, вопрос 2; Вариант 29, вопрос 3.

Ответ:

Считается, что вероятность текущего слова зависит не от всей истории, а только от последних (n) слов:

$$P(w_t | w_1, \dots, w_{t-1}) \approx P(w_t | w_{t-n}, \dots, w_{t-1})$$

Это упрощает языковую модель и лежит в основе n-грамм.

4. Для nn.RNN с batch_first=True, hidden_size=H и входом (B,T,D) укажите формы output и h_n и объясните, что содержат эти тензоры.

Встречается: Вариант 10, вопрос 4; Вариант 21, вопрос 2; Вариант 17, вопрос 5.

Ответ:

Для однослойной обычной RNN:

$$output : (B, T, H), \quad h_n : (1, B, H)$$

output содержит скрытые состояния для всех токенов последовательности, а h_n — последнее скрытое состояние.

5. Для однослойного двунаправленного nn.LSTM с batch_first=True, hidden_size=H и входом (B,T,D) укажите форму output и объясните, что содержит этот тензор.

Встречается: Вариант 10, вопрос 5; Вариант 21, вопрос 3; Вариант 27, вопрос 5.

Ответ:

Форма output:

$$(B, T, 2H)$$

Потому что для каждого токена объединяются два состояния: прямое направление слева направо и обратное направление справа налево.

6. Дайте определение интента в логике чат-бота. Приведите несколько примеров реплик пользователя и соответствующих интентов.

Встречается: Вариант 10, вопрос 6; Вариант 22, вопрос 10; Вариант 20, вопрос 6.

Ответ:

Интент — это намерение пользователя, то есть цель его сообщения. Например: «Какая завтра погода?» → weather_request; «Закажи пиццу» → food_order; «Хочу отменить бронь» → cancel_booking.

7. При дообучении матрицы W методом LoRA какие части сети замораживаются и что обучается? Запишите формулу.

Встречается: Вариант 10, вопрос 7; Вариант 21, вопрос 8; Вариант 6, вопрос 9.

Ответ:

В LoRA исходные веса модели (W) замораживаются, а обучаются только маленькие матрицы низкого ранга (A) и (B):

$$W' = W + \Delta W, \quad \Delta W = AB$$

Так модель дообучается почти как при fine-tuning, но обучаемых параметров намного меньше.

8. Как инициализируются матрицы A и B в LoRA перед началом дообучения? Почему именно так?

Встречается: Вариант 10, вопрос 8; Вариант 21, вопрос 9; Вариант 29, вопрос 8.

Ответ:

Обычно (A) инициализируется маленькими случайными значениями, а (B) — нулями. Тогда в начале $\Delta W = AB = 0$, и модель сначала ведёт себя как исходная предобученная модель.

9. Для чего прежде всего применяется квантизация весов? Назовите несколько методов квантизации.

Встречается: Вариант 10, вопрос 9; Вариант 21, вопрос 10; Вариант 17, вопрос 7; Вариант 20, вопрос 7.

Ответ:

Квантизация нужна, чтобы уменьшить размер модели, расход памяти и ускорить инференс. Методы: fp32 → fp16/bfloat16, int8/int4-квантизация, симметричная и асимметричная квантизация, линейная и range-based квантизация.

10. Назовите минимум два преимущества библиотеки vLLM по сравнению с базовой реализацией инференса Hugging Face.

Встречается: Вариант 10, вопрос 10; Вариант 28, вопрос 10; Вариант 27, вопрос 10.

Ответ:

vLLM быстрее обслуживает запросы за счёт эффективного управления KV-cache через PagedAttention. Также он поддерживает динамический батчинг, лучше использует GPU и даёт меньшую задержку при большом числе запросов.

11. Зачем в word2vec применяется negative sampling и что именно он заменяет?

Встречается: Вариант 27, вопрос 1; Вариант 22, вопрос 1; Вариант 28, вопрос 2; Вариант 18, вопрос 4.

Ответ:

Negative sampling нужен, чтобы не считать softmax по всему словарю, потому что словарь может быть очень большим. Вместо этого модель учится отличать правильную пару «слово-контекст» от нескольких случайных отрицательных примеров:

$$\log \sigma(v_c^T v_w) + \sum_{i=1}^k \log \sigma(-v_{n_i}^T v_w)$$

где (v_w) — вектор слова, (v_c) — вектор правильного контекста, (v_{n_i}) — отрицательные слова.

12. Назовите минимум два преимущества fastText перед word2vec.

Встречается: Вариант 27, вопрос 2; Вариант 22, вопрос 2; Вариант 7, вопрос 2; Вариант 40, вопрос 2.

Ответ:

fastText представляет слово как сумму эмбедингов символьных n-грамм, поэтому лучше работает с редкими словами, опечатками и словами вне словаря. Также он лучше подходит для языков с богатой морфологией, например русского, потому что учитывает части слова.

13. Чем обычно инициализируется скрытое состояние RNN на первом шаге? Приведите формулу RNN cell и объясните почему.

Встречается: Вариант 27, вопрос 3; Вариант 22, вопрос 3; Вариант 20, вопрос 1; Вариант 25, вопрос 3.

Ответ:

Обычно начальное скрытое состояние задаётся нулевым вектором:

$$h_0 = 0$$

Так делают, потому что на первом шаге у RNN ещё нет предыдущего контекста, от которого можно было бы отталкиваться.

14. Как соотносятся веса ячейки RNN на разных временных шагах одной последовательности? Покажите формулы для двух последовательных шагов.

Встречается: Вариант 27, вопрос 4; Вариант 22, вопрос 4; Вариант 30, вопрос 1; Вариант 29, вопрос 4; Вариант 25, вопрос 4.

Ответ:

Веса RNN на всех временных шагах одинаковые, то есть используются одни и те же матрицы (W_x) и (W_h). Например:

$$h_t = f(W_x x_t + W_h h_{t-1} + b)$$
$$h_{t+1} = f(W_x x_{t+1} + W_h h_t + b)$$

Это значит, что одна и та же ячейка применяется к каждому элементу последовательности.

15. Какая функция активации обычно используется для формирования нового скрытого состояния в базовой RNN? Приведите формулу.

Встречается: Вариант 27, вопрос 5; Вариант 22, вопрос 5; Вариант 30, вопрос 2; Вариант 6, вопрос 5.

Ответ:

В классической RNN обычно используется гиперболический тангенс:

$$h_t = \tanh(W_x x_t + W_h h_{t-1} + b)$$

$\tanh$ сжимает значения в диапазон $([-1;1])$ и помогает получить новое скрытое состояние.

16. Какова роль матрицы Value (V) в формуле Attention(Q,K,V)? Приведите формулу.

Встречается: Вариант 27, вопрос 6; Вариант 30, вопрос 4; Вариант 18, вопрос 6; Вариант 29, вопрос 5.

Ответ:

Формула внимания:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

(Q) и (K) определяют, на что обратить внимание, а (V) содержит сами значения, которые смешиваются по найденным весам внимания. То есть (V) — это информация, которую модель реально извлекает.

17. Чем cross-attention принципиально отличается от self-attention? Приведите пример, где используются эти типы внимания.

Встречается: Вариант 27, вопрос 7; Вариант 30, вопрос 5; Вариант 29, вопрос 6.

Ответ:

В self-attention (Q), (K), (V) берутся из одной и той же последовательности. В cross-attention запросы (Q) берутся из одной последовательности, а ключи (K) и значения (V) — из другой, например в переводе decoder смотрит на выходы encoder. В лекции cross-attention описан как работа с двумя разными последовательностями.

18. Почему Transformer требует positional encoding? Какое свойство self-attention это компенсирует?

Встречается: Вариант 27, вопрос 8; Вариант 21, вопрос 4; Вариант 28, вопрос 3; Вариант 3, вопрос 3.

Ответ:

Self-attention сам по себе не знает порядок слов: для него слова просто набор токенов, между которыми считаются связи. Positional encoding добавляет информацию о позиции токена, чтобы модель отличала «кошка поймала мышь» от «мышь поймала кошку».

19. Дайте определение slot filling в диалоговой системе и приведите пример извлечения слотов из реплики пользователя.

Встречается: Вариант 27, вопрос 9; Вариант 21, вопрос 7; Вариант 29, вопрос 7; Вариант 25, вопрос 6; Вариант 3, вопрос 6.

Ответ:

Slot filling — это извлечение конкретных параметров из реплики пользователя для выполнения интента. Например: «Забронируй столик в ресторане Утка завтра на двоих» → restaurant=Утка, date=завтра, people=2.

20. Какие этапы проходят документы в базовом пайплайне RAG перед добавлением в prompt?

Встречается: Вариант 27, вопрос 10; Вариант 30, вопрос 10; Вариант 18, вопрос 10; Вариант 7, вопрос 10; Вариант 40, вопрос 10.

Ответ:

Документы сначала очищаются и разбиваются на фрагменты/chunks, затем для них строятся эмбединги и они сохраняются в векторный индекс. После запроса пользователя находятся top-k наиболее близких фрагментов, они могут быть отфильтрованы или rerank-нуты, а затем добавляются в prompt как контекст.

21. Для nn.GRU с batch_first=True, hidden_size=N и входом (B,T,D) укажите формы output и h_n.

Встречается: Вариант 22, вопрос 6.

Ответ:

Для однослойной однонаправленной GRU:

$$\text{output} : (B, T, H), \quad h_n : (1, B, H)$$

output содержит скрытые состояния для всех токенов, а h_n — последнее скрытое состояние слоя.

22. Назовите преимущества Transformer перед RNN.

Встречается: Вариант 22, вопрос 7.

Ответ:

Transformer можно обучать параллельно, потому что он не обязан идти по токенам строго последовательно. Также self-attention лучше работает с дальними зависимостями, потому что любой токен может напрямую учитывать любой другой токен.

23. Назовите основные слои/блоки энкодера оригинального Transformer и кратко опишите их роль.

Встречается: Вариант 22, вопрос 8; Вариант 21, вопрос 6; Вариант 28, вопрос 5; Вариант 3, вопрос 5.

Ответ:

Главные блоки: self-attention, feed-forward network, residual connection, layer normalization и positional encoding. Self-attention ищет связи между токенами, FFN преобразует признаки, residual и normalization стабилизируют обучение, positional encoding добавляет порядок слов.

24. Запишите стандартную формулу одного слоя с residual connection и объясните, какую проблему решает этот прием.

Встречается: Вариант 22, вопрос 9; Вариант 7, вопрос 3; Вариант 20, вопрос 3; Вариант 40, вопрос 3.

Ответ:

Residual connection:

$$y = F(x) + x$$

где x — вход слоя, $F(x)$ — преобразование слоя. Такой пропускной путь помогает бороться с затуханием градиента и упрощает обучение глубоких сетей.

25. Назовите минимум два преимущества косинусной меры перед евклидовым расстоянием при сравнении документов.

Встречается: Вариант 21, вопрос 1; Вариант 25, вопрос 1.

Ответ:

Косинусная мера сравнивает направление векторов, а не их длину, поэтому меньше зависит от размера документа. Она хорошо подходит для разреженных TF-IDF-векторов и показывает сходство по относительному распределению слов.

26. Назовите минимум два преимущества синусоидального positional encoding перед обучаемым.

Встречается: Вариант 21, вопрос 5; Вариант 28, вопрос 4; Вариант 3, вопрос 4.

Ответ:

Синусоидальное кодирование не требует дополнительных обучаемых параметров. Также оно может обобщаться на последовательности большей длины, чем были при обучении.

27. В чем состоит эффект “бутылочного горлышка” в seq2seq на базе RNN и к каким проблемам он приводит?

Встречается: Вариант 30, вопрос 3; Вариант 18, вопрос 5.

Ответ:

В классическом seq2seq весь смысл входной последовательности сжимается в один вектор последнего скрытого состояния encoder. Из-за этого модель может терять информацию, особенно в длинных предложениях, и плохо передавать дальние зависимости.

28. В запросе “Забронируйте столик в ресторане Утка на завтра на двоих” назовите сущности и их типы.

Встречается: Вариант 30, вопрос 6; Вариант 28, вопрос 6; Вариант 17, вопрос 6; Вариант 7, вопрос 6; Вариант 40, вопрос 6.

Ответ:

Сущности: ресторан = Утка, дата = завтра, количество_людей = двое. Интент здесь — бронирование столика.

29. Что означает SFT в схеме обучения LLM? На каких данных проводится supervised fine-tuning?

Встречается: Вариант 30, вопрос 7; Вариант 7, вопрос 7; Вариант 40, вопрос 7.

Ответ:

SFT — это Supervised Fine-Tuning, то есть дообучение модели с учителем. Оно проводится на размеченных данных вида «инструкция/запрос → правильный ответ», часто на диалогах и примерах хороших ответов.

30. В чем ключевая особенность in-context learning, отличающая его от fine-tuning? Назовите преимущества и недостатки этого подхода.

Встречается: Вариант 30, вопрос 8; Вариант 28, вопрос 7; Вариант 25, вопрос 7.

Ответ:

In-context learning не меняет веса модели: примеры задачи просто добавляются в prompt. Плюс — быстро и не требует обучения; минусы — зависит от качества prompt, ограничен длиной контекста и может быть менее стабильным.

31. Слой содержит W размерности 1024×1024. Сколько обучаемых параметров добавит LoRA с рангом r=8? Покажите расчет.

Встречается: Вариант 30, вопрос 9; Вариант 7, вопрос 9; Вариант 40, вопрос 9; Вариант 27, вопрос 9.

Ответ:

LoRA добавляет две матрицы:

$$A \in \mathbb{R}^{1024 \times 8}, \quad B \in \mathbb{R}^{8 \times 1024}$$

Количество параметров:

$$1024 \cdot 8 + 8 \cdot 1024 = 8192 + 8192 = 16384$$

Итого: **16 384 обучаемых параметра.**

32. Назовите минимум два преимущества softmax перед операцией max в глубоком обучении.

Встречается: Вариант 28, вопрос 1.

Ответ:

max выбирает только один самый большой элемент и обнуляет вклад остальных, поэтому через него плохо проходит обучение. softmax превращает числа в вероятности:

$$\text{softmax}(z_i) = \frac{e^{z_i}}{\sum_j e^{z_j}}$$

Он дифференцируемый и показывает не только лучший класс, но и уверенность модели.

33. На основе чего обучается Reward Model в RLHF? Покажите пример набора данных для обучения.

Встречается: Вариант 28, вопрос 8; Вариант 18, вопрос 7; Вариант 25, вопрос 8; Вариант 3, вопрос 7.

Ответ:

Reward Model обучается на человеческих предпочтениях: человеку показывают несколько ответов модели на один запрос, и он выбирает лучший. Пример данных:

chosen: "RNN – сеть для последовательностей, которая хранит скрытое состояние."

rejected: "RNN – это просто обычная нейросеть."

Модель учится давать больший reward хорошему ответу.

34. Зачем в RLHF при обучении через PPO используется копия исходной base model? Что будет, если ее не использовать?

Встречается: Вариант 28, вопрос 9; Вариант 18, вопрос 8; Вариант 6, вопрос 7; Вариант 25, вопрос 9; Вариант 3, вопрос 8.

Ответ:

Копия исходной модели нужна как reference model, чтобы новая политика не слишком далеко уходила от изначального поведения. Обычно добавляют KL-штраф:

$$Loss = Loss_{PPO} + \beta KL(\pi_{\theta} || \pi_{ref})$$

Без reference model модель может начать «ломаться»: выдавать странные ответы, переоптимизироваться под reward и терять качество языка.

35. Запишите MLE-оценку условной вероятности биграммы $P(w_i | w_{i-1})$ и объясните обозначения.

Встречается: Вариант 17, вопрос 3.

Ответ:

$$P_{MLE}(w_i | w_{i-1}) = \frac{C(w_{i-1}, w_i)}{C(w_{i-1})}$$

где $C(w_{i-1}, w_i)$ — сколько раз биграмма встретилась в корпусе, а $C(w_{i-1})$ — сколько раз слово (w_{i-1}) было первым словом биграммы.

36. Назовите три основных гейта LSTM и укажите, какую роль они играют. Покажите общую формулу гейта.

Встречается: Вариант 17, вопрос 4; Вариант 3, вопрос 2.

Ответ:

В LSTM есть forget gate, input gate и output gate. Forget gate решает, что забыть из старой памяти, input gate — что записать в память, output gate — какую часть памяти выдать наружу. Общая формула гейта:

$$g_t = \sigma(W_g x_t + U_g h_{t-1} + b_g)$$

37. Когда симметричная квантизация уступает асимметричной в точности? Покажите пример.

Встречается: Вариант 17, вопрос 8; Вариант 29, вопрос 10; Вариант 20, вопрос 8; Вариант 27, вопрос 7.

Ответ:

Симметричная квантизация хуже, когда распределение весов или активаций сильно смещено относительно нуля. Например, если значения лежат в диапазоне $([2;10])$, симметричная шкала тратит часть уровней на отрицательные числа, которых вообще нет.

38. Назовите минимум два преимущества адаптеров перед полным fine-tuning.

Встречается: Вариант 17, вопрос 9; Вариант 7, вопрос 8; Вариант 20, вопрос 9; Вариант 40, вопрос 8; Вариант 27, вопрос 8.

Ответ:

Адаптеры обучают только небольшие дополнительные слои, поэтому требуют меньше памяти и вычислений. Ещё они не меняют основную модель, поэтому снижается риск катастрофического забывания и проще переключаться между задачами.

39. На каком свойстве матриц весов больших предобученных моделей основано теоретическое обоснование LoRA? Покажите формулу.

Встречается: Вариант 17, вопрос 10.

Ответ:

LoRA основана на предположении, что изменение весов при дообучении имеет низкий ранг. Поэтому вместо полного обновления ΔW обучаются две маленькие матрицы:

$$W' = W + \Delta W, \quad \Delta W = AB$$
$$A \in \mathbb{R}^{d \times r}, \quad B \in \mathbb{R}^{r \times k}, \quad r \ll d, k$$

40. Укажите тип семантического отношения для заданных пар слов.

Встречается: Вариант 18, вопрос 1; Вариант 6, вопрос 3.

Ответ:

собака - животное - гипонимия/гиперонимия: собака является видом животного. колесо - автомобиль - меронимия/холонимия: колесо является частью автомобиля. большой - маленький и горячий - холодный - антонимия. врач - доктор - синонимия.

41. Сформулируйте дистрибутивную гипотезу и укажите методы получения представления слов, которые на ней основаны.

Встречается: Вариант 18, вопрос 2.

Ответ:

Дистрибутивная гипотеза: слова, которые встречаются в похожих контекстах, имеют похожие значения. На ней основаны матрицы совместной встречаемости, SVD/LSA, word2vec, GloVe, fastText.

42. При словаре $|V|=2000$ и окне ± 2 какова форма матрицы совместной встречаемости и что хранят ее ячейки?

Встречается: Вариант 18, вопрос 3.

Ответ:

Матрица будет иметь форму:

$$2000 \times 2000$$

Ячейка (C_{ij}) показывает, сколько раз слово (w_j) встретилось в окне ± 2 рядом со словом (w_i). Например, если в тексте «кошка поймала мышь» при окне 1 слово «мышь» стоит рядом с «поймала», то соответствующая ячейка увеличится на 1.

43. Какова основная задача самообучения на этапе pre-training генеративных LLM? Покажите пример.

Встречается: Вариант 18, вопрос 9; Вариант 6, вопрос 8; Вариант 3, вопрос 9.

Ответ:

Главная задача — предсказание следующего токена по предыдущему контексту:

$$P(w_t | w_1, \dots, w_{t-1})$$

Например, по фразе «Сегодня хорошая...» модель должна предсказать вероятное продолжение: «погода».

44. Слово встречается 3 раза в документе из 30 термов; в коллекции 1000 документов, слово встречается в 10 из них. Запишите выражение TF-IDF с десятичным логарифмом и посчитайте значение.

Встречается: Вариант 7, вопрос 1; Вариант 40, вопрос 1; Вариант 27, вопрос 4.

Ответ:

$$\begin{aligned} TF &= \frac{3}{30} = 0.1 \\ IDF &= \log_{10} \frac{1000}{10} = \log_{10} 100 = 2 \\ TF-IDF &= TF \cdot IDF = 0.1 \cdot 2 = 0.2 \end{aligned}$$

45. Если W_Q и W_K тождественно нулевые, а V вычисляется как обычно, чему равен $Z = \text{Attention}(Q, K, V)$? Поясните через формулу.

Встречается: Вариант 7, вопрос 4; Вариант 20, вопрос 4; Вариант 40, вопрос 4.

Ответ:

Формула:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

Если $(Q=0)$ и $(K=0)$, то $(QK^T=0)$, а softmax по нулевым значениям даёт равномерные веса. Значит, выход (Z) будет усреднением строк (V) , то есть каждый токен получит примерно одинаковую смесь значений.

46. Как формулируется задача Next Sentence Prediction в предобучении BERT? Покажите пример создания обучающего примера.

Встречается: Вариант 7, вопрос 5; Вариант 20, вопрос 5; Вариант 40, вопрос 5.

Ответ:

NSP — это бинарная задача: определить, является ли второе предложение реальным продолжением первого. Пример: A = "Я пришёл домой.", B = "Я включил компьютер." → IsNext; если B = "Кошка спит на диване." из другого текста → NotNext.

47. Почему квантизация часто применяется асимметрично?

Встречается: Вариант 29, вопрос 9.

Ответ:

Асимметричная квантизация лучше подходит, когда значения не центрированы около нуля, например активации часто только положительные. Методы: int8/int4, fp16/bfloat16, симметричная и асимметричная квантизация, per-tensor/per-channel, PTQ и QAT.

48. Запишите формулу обновления c_t в LSTM и объясните, что произойдет с c_t , если forget gate $f_t=0$ по всем компонентам.

Встречается: Вариант 20, вопрос 2; Вариант 25, вопрос 5; Вариант 27, вопрос 6.

Ответ:

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$$

где (f_t) — forget gate, (i_t) — input gate, $\tilde{c}_t$ — кандидат новой памяти. Если $(f_t=0)$, старая память (c_{t-1}) полностью забывается.

49. В bfloat16 по сравнению с float16 при тех же 16 битах увеличено число бит экспоненты. Что это дает?

Встречается: Вариант 20, вопрос 10; Вариант 6, вопрос 10.

Ответ:

В bfloat16 больше бит отведено под экспоненту, поэтому он поддерживает более широкий диапазон чисел. Это делает обучение стабильнее: меньше риск overflow/underflow, хотя точность мантииссы ниже, чем у float16.

50. Запишите формулу перплексии языковой модели через перекрестную энтропию H и поясните связь с вероятностью появления текста.

Встречается: Вариант 6, вопрос 1.

Ответ:

$$PPL = e^H$$

Если энтропия считается по логарифму 2, то:

$$PPL = 2^H$$

Перплексия показывает, насколько модель «удивляется» тексту: чем выше вероятность правильного текста, тем ниже (H) и тем ниже перплексия.

51. Назовите базовую единицу WordNet и приведите минимум два типа семантических отношений между синсетами.

Встречается: Вариант 6, вопрос 2.

Ответ:

Базовая единица WordNet — синсет, то есть набор слов-синонимов, обозначающих один смысл. Между синсетами бывают отношения: гипонимия/гиперонимия, меронимия/холонимия, синонимия, антонимия.

52. Почему Skip-gram относят к self-supervised learning? Укажите, откуда берутся метки для обучения.

Встречается: Вариант 6, вопрос 4; Вариант 25, вопрос 2.

Ответ:

В Skip-gram не нужны ручные метки: обучающие пары автоматически берутся из самого текста. Центральное слово является входом, а слова из его контекстного окна становятся «метками» для обучения.

53. Назовите минимум два последствия затухания/взрыва градиентов в базовой RNN.

Встречается: Вариант 6, вопрос 6; Вариант 3, вопрос 1.

Ответ:

При затухании градиента RNN плохо запоминает дальние зависимости и почти не обучает ранние шаги последовательности. При взрыве градиента обучение становится нестабильным: loss может резко расти, веса становятся слишком большими.

54. Что дает Tree-of-Thought (ToT) по сравнению с базовым Chain-of-Thought (CoT)? Приведите пример.

Встречается: Вариант 25, вопрос 10; Вариант 3, вопрос 10.

Ответ:

CoT обычно строит одну цепочку рассуждений, а Tree-of-Thought рассматривает несколько ветвей решения и может выбирать лучшую. Например, при задаче на логику модель пробует несколько вариантов решения, оценивает их и отбрасывает неправильные.

55. Назовите минимум два преимущества векторного представления документов на основе bag-of-words/TF-IDF.

Встречается: Вариант 27, вопрос 3.

Ответ:

Такие представления простые, быстрые и хорошо работают как базовый метод для классификации и поиска документов. TF-IDF дополнительно понижает вес слишком частых слов и повышает вес более информативных терминов.
